Super-Resolution su TextZoom: confronto tra un Transformer e una CNN

Corso di Computer Vision - Università degli Studi di Catania
Anno accademico 2025/2026 - prof. S. Battiato, F. Guarnera

Studente	Matricola	Metodo sviluppato
Alessandro Sciacca	1000085546	Metodo 1 - HiT-SRF
Lorenzo Comis	1000084704	Metodo 2 - SAFMN

1. Introduzione

Il progetto affronta il problema della **Single Image Super-Resolution (SISR)**: ricostruire un'immagine ad alta risoluzione a partire da una sola immagine a bassa risoluzione. Il caso studiato è quello di ritagli di testo fotografati da insegne e cartelli, a fattore di ingrandimento 2: da immagini di 16x64 pixel a immagini di 32x128.

All'interno del progetto sono state confrontate **due architetture diverse sullo stesso task e sullo stesso dataset**, ciascuna sviluppata da uno dei due studenti:

- **HiT-SRF** (ECCV 2024), un Transformer con attention a finestre gerarchiche;
- **SAFMN** (ICCV 2023), una rete completamente convoluzionale basata su modulazione spaziale multi-scala.

La scelta non è casuale. I due modelli appartengono a famiglie architetturali opposte ma sono **pre-addestrati sullo stesso dataset (DF2K), allo stesso fattore di scala**, e in questo lavoro vengono adattati allo stesso dominio con una procedura identica. L'unica variabile che cambia è quindi l'architettura, e il confronto assume la forma di un esperimento controllato.

Questo permette di rispondere a una domanda più interessante di "quale dei due modelli è migliore": **quanto pesa la scelta dell'architettura rispetto all'adattamento al dominio applicativo?** I risultati mostrano che il secondo fattore vale circa quindici volte il primo, e che zero-shot le due architetture sono indistinguibili fra loro.

2. Il dataset

Perché TextZoom e non DIV2K

Una prima versione del lavoro utilizzava DIV2K, il dataset standard per la super-resolution. Il fine-tuning però non produceva alcun miglioramento apprezzabile, per una ragione semplice: entrambi i modelli scelti sono già pre-addestrati dagli autori su **DF2K**, cioè DIV2K unito a Flickr2K. Il fine-tuning stava riproponendo alle reti gli stessi dati che avevano già visto.

L'adattamento ha senso solo quando il dominio di destinazione è **diverso** da quello di pre-addestramento. **TextZoom** (ECCV 2020) lo è sotto due aspetti.

Le immagini a bassa risoluzione sono reali, non sintetiche. Nei dataset classici la versione LR si ottiene rimpicciolendo la HR con interpolazione bicubica: una degradazione pulita, deterministica e sempre uguale a se stessa. In TextZoom invece **entrambe le versioni sono state fotografate**, variando la lunghezza focale della fotocamera. La LR contiene quindi sfocatura ottica reale, rumore del sensore e artefatti di compressione, cioè un tipo di degradazione che i modelli non hanno mai incontrato in addestramento.

Il contenuto è di natura diversa. DF2K è composto da fotografie naturali: paesaggi, animali, persone. TextZoom è fatto di testo, che ha caratteristiche visive quasi opposte.

	Foto naturali	Testo
Bordi	sfumati, irregolari	netti, ad alto contrasto
Texture	abbondanti	quasi assenti
Strutture	organiche, variabili	tratti sottili e regolari

C'è infine un vantaggio pratico non trascurabile: su un paesaggio è difficile giudicare a occhio se la super-resolution ha funzionato, mentre su un'insegna il criterio è immediato, perché la parola o si legge o non si legge.

Composizione e limiti del dataset

TextZoom è distribuito in formato lmdb. Le immagini LR misurano 16x64 pixel e le HR 32x128, quindi il fattore di scala è **2**, non 4 come nella maggior parte dei benchmark: sono state di conseguenza usate le versioni x2 di entrambi i modelli.

Sono state impiegate **2794 coppie per l'addestramento** e le **1619 immagini** del sottoinsieme di test `easy`.

La scelta di `easy` merita una spiegazione. Poiché LR e HR sono due scatti distinti, **non sono allineate perfettamente pixel per pixel**. Metriche come PSNR e SSIM, che confrontano i pixel nella stessa posizione, sono penalizzate da questo disallineamento, che nel test set cresce passando dai livelli `easy` a `medium` e `hard`. Limitarsi a `easy` contiene il problema, al prezzo di non misurare il comportamento dei modelli sui casi più difficili.

3. Pipeline sperimentale

Tutto ciò che è comune ai due metodi è stato definito una volta sola e condiviso: caricamento del dataset, split, metriche, baseline e funzioni di valutazione. Ogni metodo deve solo fornire una funzione che, data un'immagine LR, restituisce l'immagine super-risolta; la valutazione è quindi identica per costruzione.

Baseline

Il riferimento minimo è l'**interpolazione bicubica**: nessun modello, nessun addestramento, solo ingrandimento. Serve a rispondere alla domanda "il modello sta effettivamente aggiungendo informazione, oppure si limita a ingrandire?". Un modello che non batte la bicubica non ha alcuna utilità.

Metriche

Sono state adottate tre metriche complementari, calcolate su tutte le 1619 immagini di test:

- **PSNR**, rapporto segnale/rumore derivato dall'errore quadratico medio. Misura la fedeltà pixel per pixel ed è la metrica di riferimento della letteratura sulla super-resolution. Più alto è meglio.
- **SSIM**, che confronta la struttura locale (bordi, contrasto) invece dei singoli pixel. Più alto è meglio.
- **LPIPS**, che confronta le immagini nello spazio delle feature di una rete neurale ed è la più vicina al giudizio percettivo umano. Più basso è meglio.

Ogni metrica è riportata con il proprio **intervallo di confidenza al 95%** sulla media. Inoltre sono stati conservati i punteggi immagine per immagine, il che permette il confronto appaiato descritto nella sezione dei risultati.

Procedura di adattamento

Entrambi i modelli sono stati fine-tunati con una ricetta **identica**:

Parametro	Valore
Loss	L1
Ottimizzatore	Adam
Learning rate	1e-5
Iterazioni	2000
Batch size	16
Parametri addestrati	tutta la rete
Input	immagini intere, senza ritagli

Il learning rate è due ordini di grandezza sotto quello di un addestramento da zero (2e-4): i modelli sono già competenti in generale, si tratta di specializzarli sul nuovo dominio senza distruggere quanto hanno già appreso. Viene addestrata l'intera rete e non solo gli ultimi livelli, perché a differenza della classificazione qui il compito non cambia, e la capacità di generare dettaglio è distribuita in tutta l'architettura.

Mantenere la procedura identica è la condizione che rende il confronto interpretabile: dati di pre-addestramento uguali, dati di adattamento uguali, budget di addestramento uguale. Ciò che resta diverso è l'architettura.

4. Metodo 1 - HiT-SRF

HiT-SRF è un Transformer per la super-resolution presentato a ECCV 2024.

I Transformer si basano sull'*attention*, che mette in relazione ogni pixel con tutti gli altri: un meccanismo potente ma di costo quadratico, insostenibile su un'immagine intera. La soluzione classica, introdotta da SwinIR, consiste nel calcolare l'attention solo dentro finestre di dimensione fissa, con il limite che il modello osserva sempre a una sola scala.

L'idea di HiT-SR è **far crescere le finestre con la profondità della rete**: i primi livelli usano finestre piccole e catturano i dettagli fini, quelli successivi finestre progressivamente più grandi che raccolgono il contesto. Per evitare che il costo esploda, l'attention classica è sostituita da un meccanismo il cui costo cresce in modo lineare anziché quadratico.

Il modello conta **846.944 parametri**, un ordine di grandezza meno dei Transformer per super-resolution di taglia piena, il che rende il fine-tuning praticabile su una GPU T4.

Un vincolo architetturale rilevante per questo lavoro: la rete **richiede input con dimensioni multiple di 64**. Poiché le immagini LR di TextZoom sono 16x64, ogni immagine deve essere estesa con padding fino a 64x64 e l'eccesso ritagliato dal risultato. La rete elabora quindi quattro volte l'area utile, con conseguenze sui tempi che verranno discusse più avanti.

5. Metodo 2 - SAFMN

SAFMN (*Spatially-Adaptive Feature Modulation*, ICCV 2023) è una rete **completamente convoluzionale**: nessuna self-attention, nessun meccanismo di tipo Transformer.

L'obiettivo dichiarato è ottenere una visione a più scale senza pagare il costo dell'attention. Ogni blocco suddivide le feature in gruppi ed elabora ciascun gruppo a una risoluzione diversa: uno alla risoluzione piena per i dettagli fini, gli altri progressivamente ridotti per il contesto. I gruppi vengono poi ricombinati usando le mappe a bassa risoluzione per **modulare** quelle ad alta risoluzione, cioè per decidere zona per zona quanto pesare ciascuna feature. Il risultato è un modello pensato per l'esecuzione su dispositivi mobili.

La configurazione dei pesi x2 pubblicati dagli autori corrisponde a 36 canali e 8 blocchi, per un totale di **227.820 parametri**, circa un quarto di HiT-SRF. Essendo interamente convoluzionale e basata su riduzioni di scala adattive, la rete accetta immagini di qualunque dimensione: a differenza del Metodo 1, non è necessario alcun padding.

6. Risultati

Quadro complessivo

Metodo	PSNR (dB)	SSIM	LPIPS
Bicubica (baseline)	23.42 ± 0.14	0.7359 ± 0.0054	0.1691 ± 0.0045
HiT-SRF zero-shot	23.56 ± 0.14	0.7404 ± 0.0056	0.1559 ± 0.0045
HiT-SRF fine-tuned	**25.56 ± 0.12**	**0.8346 ± 0.0039**	**0.0676 ± 0.0025**
SAFMN zero-shot	23.57 ± 0.14	0.7406 ± 0.0056	0.1579 ± 0.0045
SAFMN fine-tuned	24.89 ± 0.11	0.8157 ± 0.0041	0.0772 ± 0.0025

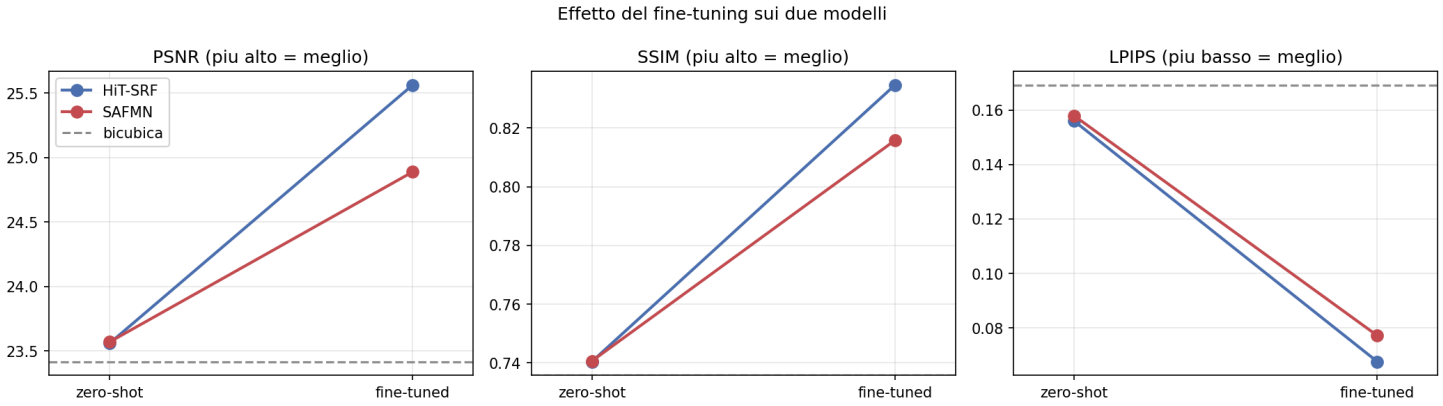


Figura 1. Effetto del fine-tuning sulle tre metriche. I due modelli partono sovrapposti e appena sopra la baseline; dopo l'adattamento si separano, con HiT-SRF davanti.

Il fine-tuning e le sue curve

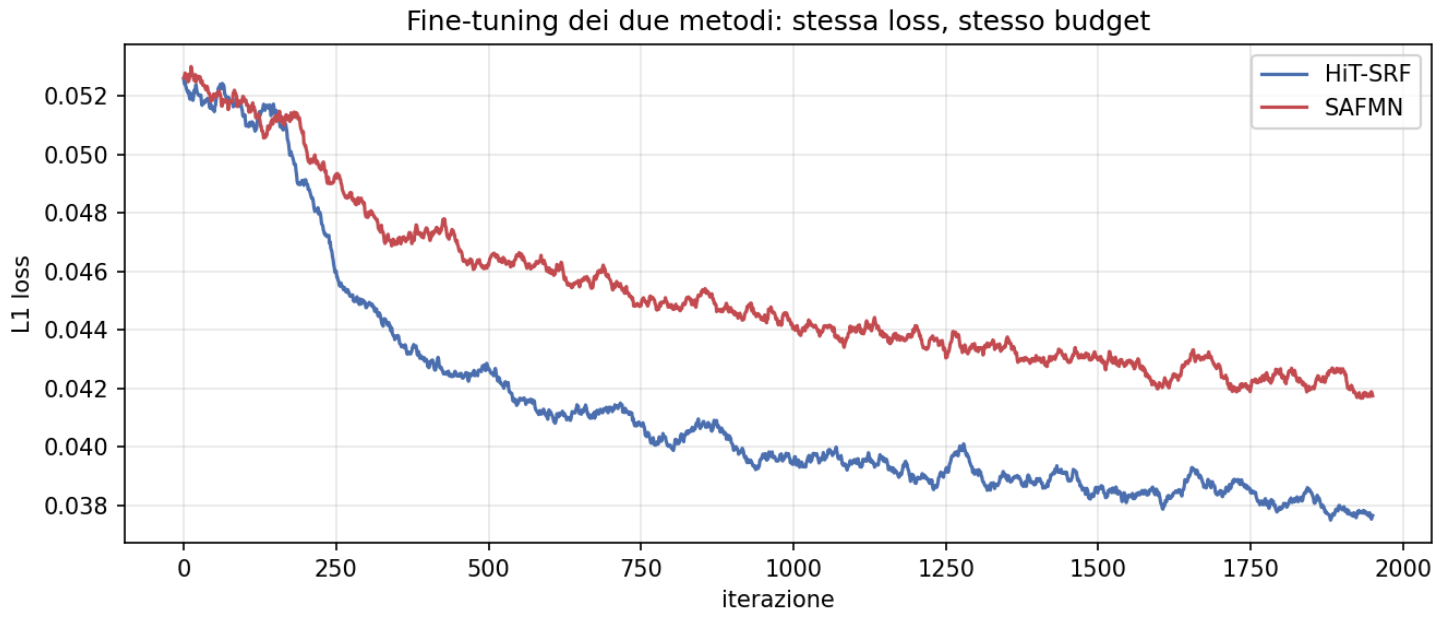


Figura 2. Le due curve sono direttamente confrontabili: stessa loss, stessi dati, stesso numero di iterazioni.

Le differenze sono reali?

Gli intervalli di confidenza della tabella misurano l'incertezza di ciascuna media presa isolatamente, ed è dominata dal fatto che alcune immagini del test set sono intrinsecamente facili e altre difficili. Da soli non permettono di stabilire se un metodo sia migliore di un altro.

Poiché i metodi sono valutati sulle **stesse identiche immagini**, il confronto corretto è appaiato: si calcola la differenza immagine per immagine e se ne studia la distribuzione. L'incertezza risultante è

molto minore, e in più si ottiene un'informazione che la media non contiene, cioè **quanto spesso** un metodo prevale.

Confronto (differenza media, IC 95%)	PSNR	SSIM	LPIPS
HiT-SRF ft meno SAFMN ft	+0.674 [+0.631, +0.716]	+0.0188 [+0.0177, +0.0199]	-0.0096 [-0.0104, -0.0087]
Immagini in cui HiT-SRF prevale	80.7%	81.7%	78.3%

Confronto contro la baseline (PSNR)	Differenza media, IC 95%	Immagini in cui prevale
HiT-SRF zero-shot meno bicubica	+0.142 [+0.120, +0.164]	58.6%
SAFMN zero-shot meno bicubica	+0.152 [+0.131, +0.173]	65.5%

Nessuno degli intervalli contiene lo zero: tutti i divari sono quindi **sistematici**, non effetti del caso. Il vantaggio di HiT-SRF dopo l'adattamento è reale e ricorrente, presente su circa quattro immagini su cinque e coerente su tutte e tre le metriche. Il vantaggio dei modelli pre-addestrati sulla bicubica, invece, è statisticamente reale ma **praticamente irrilevante**: 0.14 dB, con una frequenza di vittoria poco superiore al lancio di una moneta.

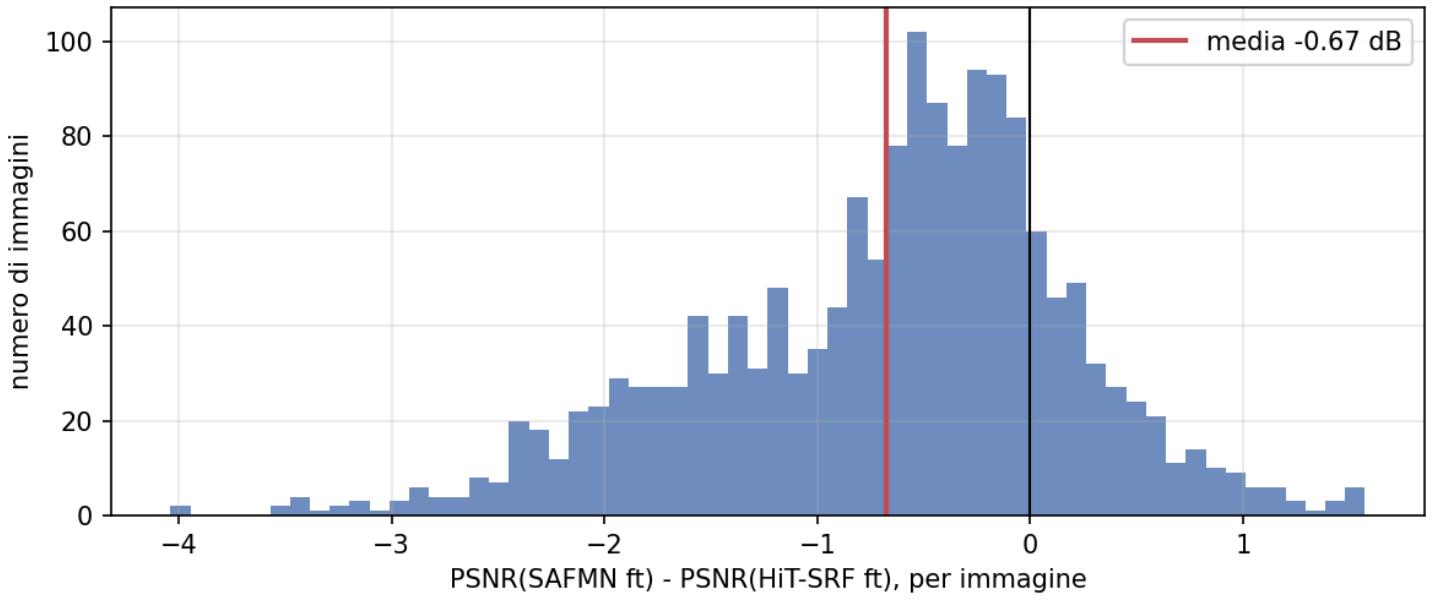


Figura 3. Distribuzione delle differenze per immagine. Attenzione al segno: la sottrazione è SAFMN meno HiT-SRF, quindi i valori negativi indicano che HiT-SRF è migliore. La linea nera è il pareggio, la linea rossa la media.

La figura mostra due proprietà che la sola media nasconde. La distribuzione è una **gobba unica** spostata a sinistra dello zero, non due popolazioni distinte: il vantaggio è diffuso su tutto il dataset e non generato da un sottoinsieme particolare di immagini. Ed è **asimmetrica**: la coda si estende fino a -4 dB da un lato e si ferma attorno a +1.6 dall'altro, il che significa che quando HiT-SRF prevale può prevalere nettamente, mentre quando è SAFMN a prevalere lo fa di poco.

Confronto visivo

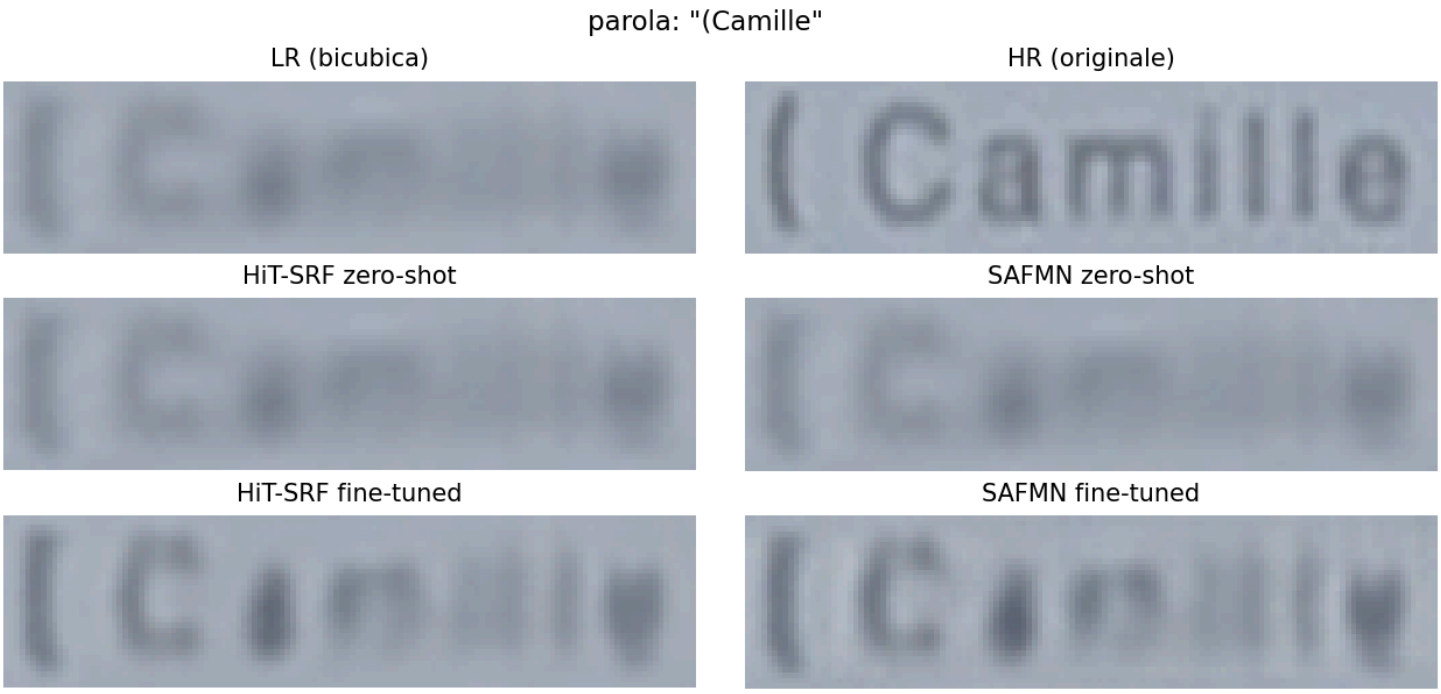


Figura 4. In alto, l'input ingrandito in modo bicubico (che coincide con la baseline) e l'originale ad alta risoluzione. Sotto, i due modelli prima e dopo il fine-tuning: HiT-SRF nella colonna di sinistra, SAFMN in quella di destra.

L'ispezione visiva conferma i numeri. Le due ricostruzioni zero-shot sono indistinguibili fra loro e quasi indistinguibili dall'ingrandimento bicubico. Dopo il fine-tuning entrambi i modelli aumentano nettamente il contrasto tra i caratteri e lo sfondo, separando tratti che nell'input erano fusi. La differenza fra le due versioni adattate, invece, è difficile da cogliere a occhio nudo, coerentemente con il divario contenuto misurato dalle metriche.

Costo computazionale

Modello	Parametri	Training (min)	Inferenza (ms/img)
HiT-SRF	846.944	44.6	173.1
SAFMN	227.820	1.1	8.2

I tempi sono misurati su GPU T4. HiT-SRF ha meno di quattro volte i parametri di SAFMN, ma è **ventuno volte più lento in inferenza e quaranta volte più lento in addestramento**.

7. Discussione

Zero-shot le due architetture sono indistinguibili. 23.56 contro 23.57 dB, 0.7404 contro 0.7406 di SSIM: un Transformer e una CNN che non condividono quasi nulla dal punto di vista strutturale producono lo stesso identico risultato. Poiché i due modelli condividono il dataset di pre-addestramento ma non l'architettura, la variabile che spiega il risultato è la prima. Applicati fuori dal dominio per cui sono stati addestrati, **è il pre-addestramento a determinare le prestazioni, non il modo in cui la rete è costruita**. La sofisticazione architetturale non produce alcun vantaggio finché il modello lavora su dati che non somigliano a quelli che ha visto.

Il valore prodotto dall'adattamento è di un altro ordine di grandezza. Sostituire l'interpolazione bicubica con un modello allo stato dell'arte, senza riaddestrarlo, vale 0.14 dB. Adattare quello stesso modello al dominio ne vale 2.00 per HiT-SRF e 1.32 per SAFMN. Il rapporto tra i due fattori è di circa quindici a uno, e riguarda i dati, non la rete.

Dopo l'adattamento la differenza architetturale emerge, ma è modesta. HiT-SRF prevale di 0.674 dB e lo fa in modo sistematico, su circa l'80% delle immagini e su tutte e tre le metriche. Il vantaggio è quindi solido, ma va pesato. Il confronto significativo non è fra i due valori assoluti di PSNR, che contengono entrambi i 23.42 dB ottenibili senza alcun modello, ma fra i rispettivi guadagni sulla baseline: 2.14 dB per HiT-SRF e 1.47 per SAFMN. Detto altrimenti, **SAFMN ottiene circa due terzi del miglioramento disponibile impiegando un ventesimo del tempo di calcolo**.

Il numero di parametri non è un indicatore affidabile del costo di calcolo. Il divario di velocità di ventuno volte a fronte di un rapporto di 3.7 volte nei parametri ha due cause. La prima è il vincolo sulle dimensioni dell'input: dovendo estendere ogni immagine da 16x64 a 64x64, HiT-SRF elabora quattro volte l'area utile. La seconda, che spiega il fattore restante, è il costo intrinseco dell'attention rispetto alla convoluzione. Il modello progettato per l'efficienza risulta quindi il più lento dei due.

Ne deriva che la domanda "quale dei due è migliore" non ha una risposta unica ma dipende dal criterio adottato. Per la massima qualità di ricostruzione la scelta è il Transformer; per qualunque impiego in cui il tempo di calcolo abbia un peso, come l'elaborazione di grandi quantità di fotogrammi o l'esecuzione su dispositivi con risorse limitate, la CNN leggera è la scelta più sensata.

8. Limiti

Il confronto sui tempi penalizza HiT-SRF in modo specifico di questo dataset. Il padding da 16x64 a 64x64 è una conseguenza delle dimensioni insolitamente piccole delle immagini di TextZoom: su immagini di taglia ordinaria quel costo aggiuntivo sparirebbe e il divario di velocità si ridurrebbe. Il fattore ventuno vale per questo scenario, non come proprietà generale dei due modelli.

Solo il sottoinsieme `easy`. I livelli `medium` e `hard`, in cui il disallineamento tra i due scatti è maggiore, non sono stati valutati.

Entrambi i metodi appartengono alla famiglia della regressione. I modelli generativi per la super-resolution non sono stati considerati: le GAN di riferimento del settore risalgono al 2021 e non rientravano nel criterio di attualità adottato, mentre i modelli a diffusione operano a scala x4 su immagini molto più grandi e non sono addestrabili con le risorse disponibili. Il confronto riguarda quindi due modi di costruire l'architettura, non due modi di definire l'obiettivo di ottimizzazione.

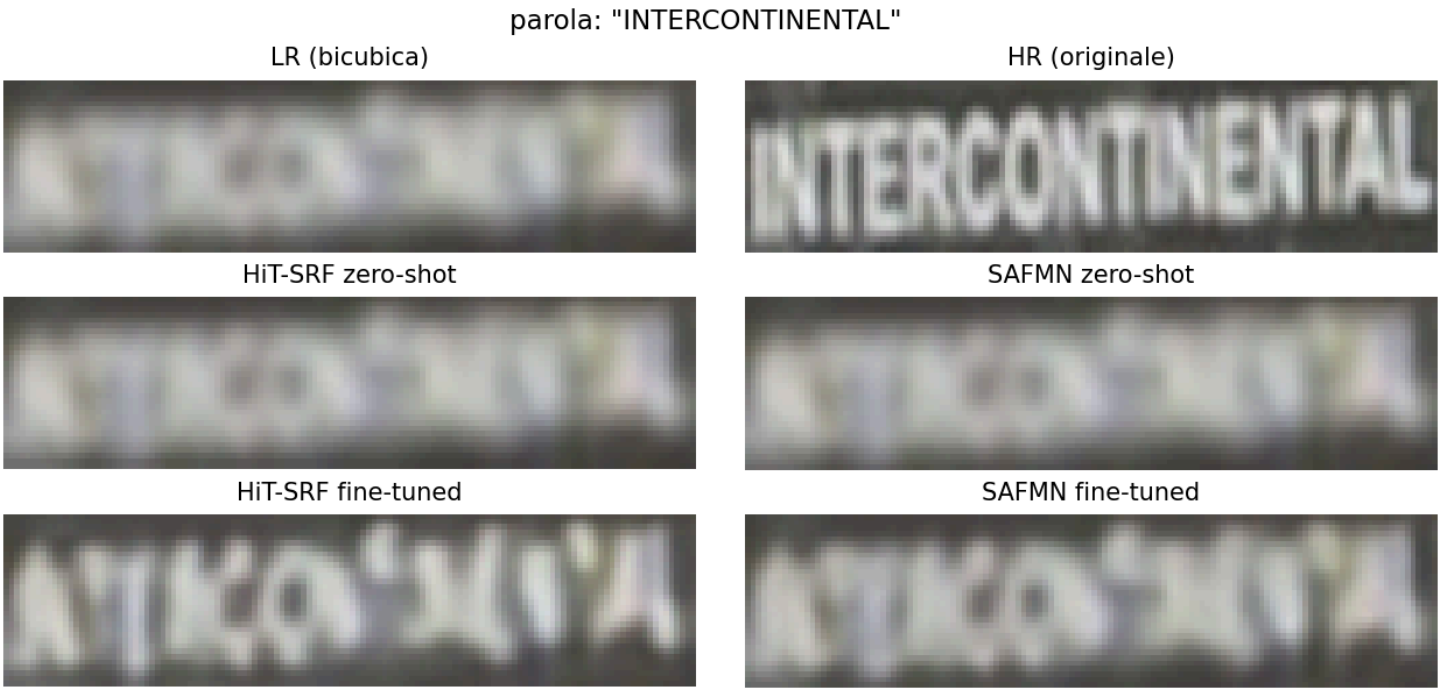


Figura 5. Uno dei ritagli su cui il metodo migliore ottiene il punteggio LPIPS peggiore. La parola originale è "INTERCONTINENTAL", ma nell'input quell'informazione è ormai perduta: dopo il fine-tuning entrambi i modelli producono caratteri nitidi e del tutto errati. Aumentare il contrasto non equivale a recuperare il contenuto.

9. Conclusioni

Il confronto tra un Transformer e una CNN per la super-resolution, condotto a parità di dati di pre-addestramento, di dominio di destinazione e di procedura di adattamento, porta a tre conclusioni.

Su un dominio nuovo l'adattamento conta molto più dell'architettura. Il guadagno ottenuto adattando un modello al proprio dominio applicativo è circa quindici volte quello ottenuto scegliendo un modello allo stato dell'arte al posto di un'interpolazione.

Zero-shot l'architettura è irrilevante. Due reti profondamente diverse, pre-addestrate sugli stessi dati, falliscono in modo indistinguibile sul dominio nuovo. Il limite non risiede in come la rete elabora l'immagine, ma in cosa ha imparato a ricostruire.

Dopo l'adattamento la differenza emerge, ma va pesata sul costo. HiT-SRF è sistematicamente migliore, su circa l'80% delle immagini e di 0.674 dB; SAFMN ottiene il 69% dello stesso miglioramento a un ventunesimo del costo di inferenza. Quale sia il modello preferibile dipende quindi dal vincolo dominante nell'applicazione.

Uno sviluppo naturale del lavoro consiste nell'estendere la valutazione ai sottoinsiemi `medium` e `hard`, e nell'affiancare alle metriche adottate una misura di accuratezza di riconoscimento del testo tramite OCR, che sul dominio di TextZoom risponderebbe alla domanda più diretta di tutte: se la parola, dopo la ricostruzione, sia effettivamente leggibile.

10. Riferimenti

- X. Zhang et al., *HiT-SR: Hierarchical Transformer for Efficient Image Super-Resolution*, ECCV 2024. arXiv:2407.05878 - repository
- L. Sun et al., *Spatially-Adaptive Feature Modulation for Efficient Image Super-Resolution*, ICCV 2023. arXiv:2302.13800 - repository
- W. Wang et al., *Scene Text Image Super-Resolution in the Wild*, ECCV 2020. arXiv:2005.03341 - repository
- R. Zhang et al., *The Unreasonable Effectiveness of Deep Features as a Perceptual Metric*, CVPR 2018 (metrica LPIPS). arXiv:1801.03924